Humanos como Arquitetos de Orquestração: um estudo de caso sobre supervisão de agentes de IA no desenvolvimento de software

Anderson de Souza Lima[1], Ianne Lima Nogueira[1]

[1]Instituto Federal de Educação, Ciência e Tecnologia Fluminense
CEP 28360-000 – Bom Jesus do Itabapoana – RJ – Brasil

{anderson.lima,ianne.nogueira}@iff.edu.br

Abstract. Introduction: *The use of LLMs in software development has shifted the human role toward coordination and supervision of AI-driven processes.* ***Objective:*** *To investigate multi-agent orchestration as an emerging HCI model in a public technical education context.* ***Methodology:*** *Exploratory case study with nine AI agents coordinated by Paperclip, with governance defined in AGENTS.md and predominantly local operation using qwen2.5:14b and gpt-oss-120b.* ***Results:*** *The experience produced a traceable environment with auditable runs, versioned commits and AI-generated documentation, indicating that multi-agent architectures may shift interaction from direct software manipulation toward the governance of partially autonomous processes.*

Keywords *Agent orchestration, Local LLM, Human-agent interaction, Software development, Technical education.*

Resumo. Introdução: *O uso de LLMs no desenvolvimento de software tem deslocado o papel humano para a coordenação e supervisão de processos conduzidos por agentes de IA.* ***Objetivo:*** *Investigar a orquestração multiagente como modelo emergente de IHC em contexto de ensino técnico público.* ***Metodologia:*** *Estudo de caso exploratório com nove agentes coordenados pela plataforma Paperclip, com governança em AGENTS.md e operação predominantemente local com os modelos qwen2.5:14b e gpt-oss-120b.* ***Resultados:*** *A experiência produziu um ambiente rastreável com runs auditáveis, commits versionados e documentação gerada por IA, indicando que arquiteturas multiagentes podem deslocar a interação da manipulação direta do software para a governança de processos parcialmente autônomos.*

Palavras-Chave *Orquestração de agentes, LLM local, Interação humano-agente, Desenvolvimento de software, Ensino técnico.*

1. Introdução

O avanço recente dos Modelos de Linguagem de Grande Escala (Large Language Models — LLMs) tem ampliado significativamente as possibilidades de automação em atividades relacionadas ao desenvolvimento de software. Ferramentas baseadas em IA generativa passaram a atuar na escrita de código, documentação, revisão técnica e análise de requisitos, alterando gradualmente a forma como programadores interagem com ambientes de desenvolvimento [Chen *et al*. 2024; Barke *et al*. 2023]. Entretanto, grande parte dessas abordagens ainda se concentra em interações individuais entre humano e

modelo, normalmente limitadas à geração pontual de trechos de código ou respostas em linguagem natural.

Paralelamente, emergem arquiteturas baseadas em múltiplos agentes especializados, nas quais diferentes modelos ou instâncias de IA assumem papéis organizacionais distintos e colaboram entre si durante o ciclo de desenvolvimento de software [Hong *et al*. 2023; Qian *et al*. 2024]. Nesse contexto, o papel humano deixa de se concentrar exclusivamente na implementação direta e passa a envolver atividades de coordenação, supervisão, definição de escopo e validação das entregas produzidas pelos agentes. Essa mudança desloca a interação humano-computador para um modelo baseado em orquestração, no qual o humano acompanha execuções, interpreta artefatos e toma decisões sobre processos parcialmente autônomos.

Em ambientes educacionais, particularmente no ensino técnico integrado, esse cenário apresenta potencial relevante. Projetos de desenvolvimento de software frequentemente enfrentam desafios relacionados à heterogeneidade do conhecimento técnico entre estudantes, à dificuldade de acompanhamento contínuo por parte do orientador e à limitação de tempo para documentação e revisão das entregas. Nesse contexto, sistemas multiagentes baseados em LLMs podem atuar não apenas como ferramentas de apoio à programação, mas como participantes ativos da dinâmica de desenvolvimento, assumindo funções específicas dentro de estruturas organizacionais supervisionadas por humanos [Zaina *et al*. 2024].

Este artigo apresenta um estudo de caso conduzido a partir de trabalhos produzidos na disciplina de Análise e Projeto de Sistemas do Curso Técnico em Informática de uma instituição pública de ensino localizada no interior do estado do Rio de Janeiro. Os documentos de análise e requisitos elaborados pelos estudantes serviram como base para o desenvolvimento do Sistema de Gestão do Laboratório de Hardware 2025 por uma arquitetura multiagente. Os estudantes, contudo, não atuaram como operadores da plataforma de orquestração. A experiência analisada concentrou-se na atuação do coordenador humano, responsável pela definição dos papéis dos agentes, configuração dos mecanismos de governança e supervisão das interações estabelecidas durante o desenvolvimento.

Utilizando a plataforma Paperclip como ambiente de orquestração, a experiência envolveu a distribuição de tarefas entre agentes com funções distintas, o monitoramento de execuções, *commits* e *issues* produzidos autonomamente e a tomada de decisão sobre momentos de intervenção no fluxo de trabalho. Nesse contexto, a interação deixou de ocorrer predominantemente entre programador e código e passou a se concentrar na coordenação de uma equipe não-humana composta por agentes executados majoritariamente por modelos de linguagem locais e organizados segundo protocolos de governança voltados à continuidade das tarefas e à redução da dependência de intervenções humanas imediatas.

A experiência produziu um ambiente rastreável de interação humano-agente, composto por *runs* auditáveis, *commits* versionados, *issues* processadas autonomamente, documentação técnica gerada por IA e mecanismos contínuos de supervisão realizados pelo coordenador humano. Diferentemente de abordagens centradas apenas na geração automática de código [Hong *et al*. 2023; Qian *et al*. 2024], o foco deste trabalho está na análise da orquestração multiagente como forma emergente de interação humano-computador no desenvolvimento de software.

A questão de pesquisa que orienta o estudo é: como se caracteriza a atuação do humano na coordenação e supervisão de agentes especializados de IA durante um processo de desenvolvimento de software parcialmente autônomo? A unidade de análise corresponde à dinâmica de coordenação estabelecida entre o coordenador humano, a plataforma de orquestração e os agentes especializados ao longo do desenvolvimento do sistema.

As principais contribuições do trabalho são: (i) a descrição de um ambiente rastreável de coordenação humano-agente baseado predominantemente em LLMs locais; (ii) a discussão do papel humano como arquiteto da orquestração em processos parcialmente autônomos; e (iii) a análise exploratória da viabilidade técnica dessa arquitetura em contexto institucional de ensino técnico público. O trabalho se caracteriza como resultado emergente por documentar a transição observada entre um modelo de supervisão humana contínua e uma estrutura de auto-supervisão entre agentes, com a intervenção humana progressivamente concentrada em situações de exceção. Por se tratar de um estudo exploratório conduzido com um único coordenador e uma única plataforma, os resultados não pretendem ser generalizados para outros contextos educacionais ou organizacionais.

2. Interação Humano-Agente e Orquestração Multiagente

2.1. Ondas da IHC e Desafios Emergentes da Interação com IA

A trajetória histórica da Interação Humano-Computador pode ser compreendida por meio de três ondas de desenvolvimento, cada uma marcada por transformações no modo como humanos e sistemas computacionais se relacionam [Duarte e Baranauskas 2016]. A primeira onda, ancorada na ciência cognitiva e nos fatores humanos, tratava o humano como componente previsível de um sistema, buscando otimizar a interface para eficiência e redução de erros. A segunda onda ampliou o foco para além do indivíduo isolado, incorporando contextos colaborativos e práticas situadas. Já a terceira onda deslocou a centralidade para a experiência, os valores e o significado da interação em contextos cotidianos, plurais e culturalmente situados.

A disseminação de sistemas baseados em IA generativa amplia questões que extrapolam parcialmente os escopos originalmente discutidos por essas três ondas. Quando um LLM passa a escrever código, revisar artefatos ou tomar decisões técnicas de forma parcialmente autônoma, o humano deixa de interagir apenas com a interface do sistema produzido e passa também a supervisionar o processo que o produz. Essa reconfiguração levanta novas questões para o campo de IHC: o que significa supervisionar uma equipe não-humana? Como se distribui a agência em ambientes nos quais agentes de IA produzem artefatos rastreáveis e auditáveis?

Essas questões também dialogam com discussões clássicas sobre automação e controle supervisório, nas quais o aumento da autonomia computacional desloca parte da atuação humana da execução direta para atividades de monitoramento, supervisão e tomada de decisão [Sheridan 1992; Parasuraman *et al*. 2000]. Embora esses trabalhos antecedam os sistemas baseados em LLMs, oferecem uma base conceitual relevante para compreender a redistribuição de responsabilidades entre humanos e agentes computacionais.

O GranDIHC-BR 2025–2035 posiciona essas questões entre os desafios centrais para a próxima década. O GC6 discute as implicações da Inteligência Artificial em IHC a partir de três eixos relacionados a paradigmas, ética e diversidade, equidade e inclusão [Duarte *et al*. 2024]. O GC7, por sua vez, compreende a interação com tecnologias emergentes como um ecossistema integrado por humanos, tecnologias e contextos interdependentes [Zaina *et al*. 2024]. Nesse sentido, o presente trabalho não busca propor uma nova onda da IHC, mas investiga uma forma emergente de interação humano-agente caracterizada pela supervisão e coordenação de processos parcialmente autônomos.

2.2. Agentes Especializados no Desenvolvimento de Software

A ideia de distribuir atividades de desenvolvimento de software entre agentes especializados baseados em LLMs emergiu como linha de pesquisa a partir de 2023. Hong *et al.* [2023] propõem o MetaGPT, um framework de meta-programação no qual agentes assumem papéis organizacionais análogos aos de equipes de software, como gerente de produto, arquiteto, engenheiro e testador, comunicando-se por meio de procedimentos operacionais padronizados para reduzir inconsistências e alucinações em cascata. Qian *et al*. [2024] apresentam o ChatDev, no qual agentes com funções organizacionais distintas colaboram por meio de conversas estruturadas para produzir software funcional a partir de uma única descrição textual de requisitos, demonstrando que a divisão de responsabilidades entre agentes pode reduzir erros e aumentar a completude dos artefatos produzidos.

Apesar dos avanços, esses trabalhos apresentam limitações relevantes para o contexto deste artigo. Suas avaliações concentram-se predominantemente em ambientes experimentais e na autonomia dos agentes, na qualidade do código produzido e na completude dos artefatos. O papel do humano responsável por configurar, acompanhar e intervir na atuação desses agentes não constitui o principal objeto de investigação. Chen *et al*. [2024], em revisão sistemática abrangendo 947 estudos sobre LLMs em Engenharia de Software, observam que grande parte da literatura permanece centrada em tarefas isoladas de geração de código, dedicando menor atenção à dimensão humana dos processos de desenvolvimento mediados por IA.

No plano da interação individual entre humano e ferramenta de IA, Barke *et al*. [2023] documentam como programadores alternam entre dois modos distintos de uso de sistemas de geração de código: um modo de aceleração, no qual a ferramenta sugere e o humano aceita ou rejeita rapidamente, e um modo de exploração, no qual o humano usa as sugestões como ponto de partida para investigar possibilidades que não havia considerado. Os autores demonstram que mesmo interações pontuais com modelos de linguagem reestruturam o fluxo de trabalho humano, deslocando parte da carga cognitiva da implementação para a avaliação e validação das saídas geradas.

Essa observação é relevante para o presente trabalho porque, em uma arquitetura multiagente, esse deslocamento assume maior abrangência: o humano deixa de avaliar apenas sugestões pontuais e passa a acompanhar ciclos completos de execução conduzidos por agentes especializados, operando de forma parcialmente autônoma. Nesse cenário, as relações entre humanos e agentes podem envolver diferentes modalidades de colaboração. Zou *et al.* [2025] organizam essas interações em quatro subtipos: delegação, supervisão, cooperação e coordenação. É nesse deslocamento, da avaliação pontual de sugestões para a supervisão de arquiteturas multiagentes, que se concentra a contribuição exploratória deste trabalho para o campo de IHC.

2.3. Interação Humano-Agente: Supervisão, Coordenação e Orquestração

À medida que sistemas agênticos passam a executar atividades complexas de forma parcialmente autônoma, a questão de como e quando o humano deve intervir torna-se central para a pesquisa em IHC. Mozannar *et al.* [2025] introduzem o Magentic-UI, uma interface de código aberto voltada ao estudo de sistemas com humano no ciclo (human-in-the-loop), propondo mecanismos de interação voltados ao co-planejamento, co-execução, multitarefa, guardas de ação e memória de longo prazo. Os autores argumentam que sistemas agênticos supervisionados por humanos representam um caminho promissor para equilibrar autonomia e controle em contextos nos quais os modelos ainda apresentam falhas e inconsistências, perspectiva alinhada à experiência relatada neste trabalho.

Discussões recentes também têm chamado atenção para os desafios de transparência, atribuição, agência e possível perda de habilidades em experiências de automação agêntica [Spitzer *et al.* 2026]. Em sua proposta de workshop no CHI EA 2026, Spitzer *et al*. destacam a necessidade de repensar a interação entre humanos e sistemas compostos por agentes que atuam de forma coordenada. Inspirado por essa discussão, o presente trabalho utiliza a expressão interface da orquestração para designar o conjunto de mecanismos pelos quais o humano acompanha, interpreta e intervém em processos conduzidos por agentes especializados. Essa perspectiva dialoga com o que Pereira *et al*. [2024] identificam como um dos grandes desafios de IHC no Brasil: compreender como humanos e tecnologias emergentes coexistem em ecossistemas interdependentes, nos quais autonomia computacional e controle humano precisam ser continuamente negociados.

Resultado convergente foi identificado por Borges *et al.* [2025] em contexto distinto: ao investigar o uso de IA generativa na análise qualitativa em pesquisa de IHC, os autores concluem que, embora a IA ofereça ganhos de eficiência consideráveis, a supervisão humana permanece indispensável para garantir interpretação precisa e alinhamento contextual das saídas geradas. Esse achado reforça a convergência entre domínios distintos quanto à importância da supervisão humana em ecossistemas mediados por IA generativa.

Zou *et al.* [2025] organizam as modalidades de colaboração entre humanos e agentes baseados em LLMs em quatro subtipos: delegação, supervisão, cooperação e coordenação. Essa classificação contribui para compreender a experiência analisada neste trabalho, na qual o coordenador humano delegava atividades aos agentes, supervisionava execuções, coordenava prioridades e acompanhava formas de cooperação estabelecidas entre papéis especializados.

O presente trabalho contribui para essa discussão ao relatar um caso concreto em que o humano coordenador atuou como arquiteto da orquestração, definindo papéis, configurando gatilhos, interpretando artefatos e decidindo momentos de intervenção em um projeto de desenvolvimento de software conduzido por agentes especializados de IA. Diferentemente de Mozannar *et al.* [2025], cuja proposta se concentra em uma interface experimental para sistemas agênticos com humano no ciclo, e de Spitzer *et al.* [2026], que discutem desafios emergentes da automação agêntica em uma proposta de workshop, este estudo analisa a supervisão de agentes especializados em um ambiente institucional de ensino técnico público, marcado por restrições de conectividade, custo e infraestrutura computacional. Borges *et al.* [2025], por sua vez, investigam a supervisão humana em tarefas de análise qualitativa, em um contexto distinto daquele abordado neste trabalho.

3. Estudo de Caso: Coordenação Humano-Agente no Desenvolvimento de Software

3.1. Contexto do Estudo

O estudo foi conduzido a partir de trabalhos produzidos na disciplina de Análise e Projeto de Sistemas do Curso Técnico em Informática de uma instituição pública de ensino localizada no interior do estado do Rio de Janeiro, durante o desenvolvimento do Sistema de Gestão do Laboratório de Hardware 2025. O sistema tinha como objetivo apoiar o gerenciamento de empréstimos, equipamentos, patrimônio e atividades administrativas do laboratório utilizado nas disciplinas técnicas do curso, caracterizando um estudo de caso exploratório sobre a dinâmica de interação entre o coordenador humano e agentes especializados de IA [Yin 2015].

Os documentos de análise e requisitos elaborados pelos estudantes ao longo da disciplina foram utilizados como base documental para a definição do escopo e alimentação da arquitetura multiagente. Os estudantes, contudo, não operaram a plataforma de orquestração nem atuaram como coordenadores dos agentes. Portanto, o estudo não avaliou sua experiência de uso, carga cognitiva ou capacidade de supervisão da arquitetura. A unidade de análise correspondeu à dinâmica de coordenação estabelecida entre o coordenador humano, a plataforma Paperclip e os agentes especializados durante o desenvolvimento do sistema.

O projeto foi conduzido por meio de uma arquitetura de orquestração baseada em agentes especializados de IA. Nesse cenário, o coordenador humano deixou de concentrar sua atuação na escrita direta de código e passou a exercer funções relacionadas à orientação do escopo, à distribuição de responsabilidades, ao acompanhamento das execuções e à supervisão das decisões tomadas pelos agentes.

A experiência ocorreu em ambiente institucional de ensino técnico público, caracterizado por limitações de infraestrutura, conectividade e orçamento para utilização contínua de serviços externos de IA. Nos primeiros ciclos, foram utilizados modelos externos gratuitos, posteriormente substituídos após o esgotamento dos limites de uso. A partir dessa transição, a orquestração passou a operar com modelos executados localmente. Essa mudança constitui uma limitação metodológica, pois não permite isolar completamente os efeitos decorrentes da alteração dos modelos daqueles relacionados à evolução dos mecanismos de orquestração.

3.2. Arquitetura da Orquestração

A coordenação das atividades foi realizada por meio da plataforma Paperclip, utilizada como ambiente de acompanhamento das execuções, organização das tarefas e monitoramento da atuação dos agentes especializados. A interface permitia visualizar *runs*, *commits*, *issues*, histórico de atividades e estados de execução, funcionando como espaço central de interação entre o coordenador humano e os agentes envolvidos no desenvolvimento.

A arquitetura foi estruturada a partir da definição de papéis organizacionais específicos para os agentes, de modo semelhante à distribuição de responsabilidades observada em equipes humanas de desenvolvimento de software [Hong *et al.* 2023; Qian *et al.* 2024]. Em vez de um único modelo responsável por todas as tarefas, a orquestração distribuía atividades entre nove agentes especializados em funções distintas. A Tabela 1

apresenta os agentes configurados, os modelos utilizados ao longo da experiência, suas capacidades de contexto e seus papéis na arquitetura de orquestração.

Tabela 1 — Agentes, modelos e papéis na arquitetura de orquestração.

Agente	Modelo inicial	Contexto inicial	Modelo local final	Contexto final	Papel Principal
CEO Técnico Local	deepseek-v4-flash:free	1M	qwen2.5:14b	32k	Decisão técnica e priorização de *issues*
Documentador Acadêmico	gpt-oss-120b	128k	gpt-oss-120b	128k	Geração e manutenção de documentação em conformidade com a ABNT
Documentador Acadêmico Free	gpt-oss-120b	128k	gpt-oss-120b	128k	Suporte à documentação e revisão de conteúdo
Analista de Negócios Free	qwen2.5:14b	32k	qwen2.5:14b	32k	Requisitos, regras de negócio e organização do *backlog*
Codex Revisor — Lab Hardware	GPT-5.3-Codex	não informado	qwen2.5:14b	32k	Revisão de código e fechamento de *issues*
Dev Full Stack Banco — offline	qwen2.5:14b	32k	qwen2.5:14b	32k	Banco de dados, *migrations* e esquema MySQL
Dev Full Stack Local — offline	qwen2.5:14b	32k	qwen2.5:14b	32k	Desenvolvimento PHP, *front-end* e CRUDs
Executor Segurança Offline	qwen2.5:14b	32k	qwen2.5:14b	32k	Auditoria de segurança: XSS, CSRF, *rate limiting* e CSP
Gemini Supervisor — Lab Hardware	gpt-oss-120b	128k	gpt-oss-120b	128k	Supervisão de qualidade e consistência entre módulos

Nota: os nomes “Codex Revisor” e “Gemini Supervisor” correspondem aos papéis organizacionais definidos na arquitetura e não indicam o uso continuado dos modelos comerciais associados a essas denominações. Após o esgotamento dos limites de uso dos serviços externos, a orquestração passou a operar integralmente com modelos locais de código aberto.

Nos primeiros ciclos, foram utilizados modelos acessados por serviços externos, entre eles o deepseek-v4-flash:free e o GPT-5.3-Codex, este último por meio do GitHub Copilot em modalidade gratuita, porém sujeita a limites de uso. Esses modelos deixaram de ser utilizados após o esgotamento dos respectivos limites, que tornava os agentes temporariamente inoperantes. A partir dessa transição, a orquestração passou a operar integralmente com modelos de código aberto executados localmente, principalmente o qwen2.5:14b e o gpt-oss-120b.

Os agentes configurados com o gpt-oss-120b, com janela de contexto de 128k tokens, foram destinados a tarefas que exigiam referência simultânea a múltiplos artefatos, como documentação acadêmica, supervisão de qualidade e decisões arquiteturais. Apesar da elevada demanda de memória e da menor velocidade de execução no hardware disponível, o modelo apresentou funcionamento estável e capacidade suficiente para essas atividades.

Para tarefas mais focadas, como implementação de módulos específicos, revisão pontual de código e auditoria de segurança, foram alocados agentes com o modelo qwen2.5:14b, com contexto de 32k tokens. O agente inicialmente configurado com GPT-5.3-Codex, por exemplo, teve sua função posteriormente assumida pelo qwen2.5:14b após o esgotamento do limite de uso do serviço externo.

O CEO Técnico Local representou uma exceção: apesar de operar com contexto reduzido, era responsável por organizar o *backlog* e distribuir tarefas entre os demais agentes, exigindo maior velocidade de resposta. Como forma de compensar essa limitação, suas ações de reorganização e criação de pré-estudos eram revisadas em blocos por agentes com contexto de 128k *tokens*, buscando preservar a coerência das decisões ao longo das execuções.

A substituição dos modelos externos pelos modelos locais ocorreu nos primeiros ciclos da experiência. Por esse motivo, não é possível isolar completamente se os erros e conflitos observados nessa etapa decorreram da configuração inicial da orquestração, das diferenças de capacidade entre os modelos utilizados ou da combinação desses fatores. Essa condição constitui uma limitação metodológica do estudo.

A Figura 1 apresenta uma visão geral da arquitetura de orquestração utilizada no estudo, destacando o papel do coordenador humano, da plataforma Paperclip, dos agentes especializados e dos mecanismos de governança envolvidos na produção dos artefatos do sistema.

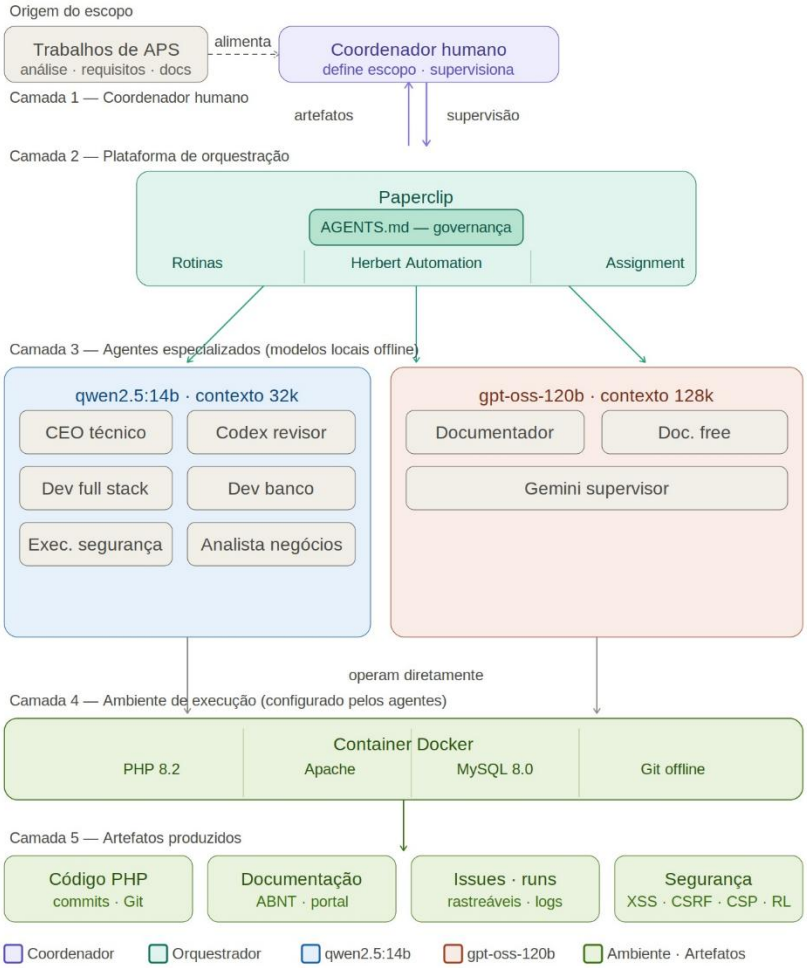


Figura 1 — Arquitetura da orquestração humano-agente utilizada no desenvolvimento do Sistema de Gestão do Laboratório de Hardware 2025, evidenciando os trabalhos de APS como origem do escopo, a governança definida nos arquivos AGENTS.md, a plataforma Paperclip como interface de mediação, os agentes especializados organizados por capacidade de contexto, o ambiente de execução configurado pelos agentes e os artefatos produzidos ao longo do desenvolvimento.

3.3. Dinâmica de Interação Humano-Agente

A interação entre o coordenador humano e os agentes não ocorreu por meio de comandos isolados para geração de código, mas pela condução contínua de um ecossistema de desenvolvimento mediado por IA. O coordenador humano atuava principalmente na definição inicial dos papéis dos agentes, na distribuição das responsabilidades, na criação de gatilhos de execução e na interpretação dos artefatos produzidos ao longo do processo.

Três mecanismos de ativação foram utilizados na plataforma Paperclip: Rotinas, para execuções periódicas automáticas, como auditorias recorrentes de *issues*; Herbert Automation, para execuções disparadas pelos agentes, que buscavam tarefas de acordo com sua lista de *issues* registrada em arquivo .md no repositório, abrangendo desde correções de *bugs* até estudos técnicos, envio de *commits* e fechamento de *issues*; e Assignment, para atribuição direta de uma tarefa pelo coordenador humano. Nesse último mecanismo, o agente iniciava o protocolo de governança, realizava um pré-estudo e uma

simulação, submetia-os à validação do supervisor da área e do CEO Técnico Local e, somente após essa etapa, iniciava a implementação.

Nos primeiros ciclos de execução, foram registrados episódios em que os agentes produziram alterações inconsistentes ou que comprometeram a estabilidade do sistema. A inspeção dos *logs* indicou que parte desses episódios estava associada ao carregamento de grandes volumes de contexto pouco relacionados à tarefa em execução. Em resposta, foi introduzido um mecanismo organizacional baseado em pré-estudos obrigatórios. Antes de iniciar uma execução, os agentes verificavam a existência de um documento preliminar contendo escopo reduzido, contexto específico da atividade e orientações sobre os arquivos ou componentes que deveriam ser modificados. Caso o pré-estudo não existisse, a implementação era interrompida, e o agente elaborava o documento para validação do supervisor da área e do CEO Técnico Local.

Um exemplo concreto ocorreu na *issue* LIM-274, referente à implementação de *rate limiting* no fluxo de autenticação. Antes da alteração do código, foi produzido o pré-estudo docs/estudos/LIM-274-rate-limit-estudo.md, que delimitou a vulnerabilidade, restringiu o escopo ao processo de *login* e definiu o limite de cinco tentativas por endereço IP, o bloqueio por 15 minutos e o registro administrativo das ocorrências. O documento foi submetido à validação do supervisor da área e do CEO Técnico Local. Após essa etapa, o agente Executor Segurança Offline implementou o controle e o registro das tentativas no arquivo src/admin/login_log.php, incorporando a funcionalidade às regras de negócio do sistema. Após a adoção desse mecanismo, observou-se menor recorrência de alterações inconsistentes associadas à ausência de delimitação prévia das tarefas.

A experiência também indicou que a autonomia dos agentes dependia de mecanismos explícitos de governança organizacional. Nos primeiros testes, foram registrados conflitos relacionados a prioridades, decisões arquiteturais e interpretação de requisitos, que produziram bloqueios e paralisações de tarefas. Para reduzir esses episódios, foram introduzidas hierarquias explícitas entre agentes e perfis comportamentais diferenciados. Os agentes responsáveis pela supervisão estratégica receberam maior autonomia decisória, enquanto os agentes executores foram configurados para seguir o ciclo de validação dos pré-estudos antes de qualquer implementação.

Durante o desenvolvimento, o acompanhamento das atividades ocorreu por meio da análise de *runs*, *commits*, documentação gerada automaticamente e *issues* processadas pelos agentes. Cada execução gerava um *run* com identificador único, *timestamp*, duração e consumo de tokens, constituindo um registro auditável da atividade realizada. Um instrumento adicional de supervisão foi o portal de documentação criado pelos próprios agentes, que organizava discussões, fila de tarefas e resultados. Em situações que exigiam maior detalhamento, o coordenador consultava diretamente os *runs* no painel do Paperclip.

A Figura 2 apresenta a interface da plataforma Paperclip utilizada durante o estudo, que funcionava como principal espaço de mediação da interação humano-agente e permitia ao coordenador acompanhar execuções, observar o estado operacional dos agentes e interpretar os *logs* produzidos automaticamente.

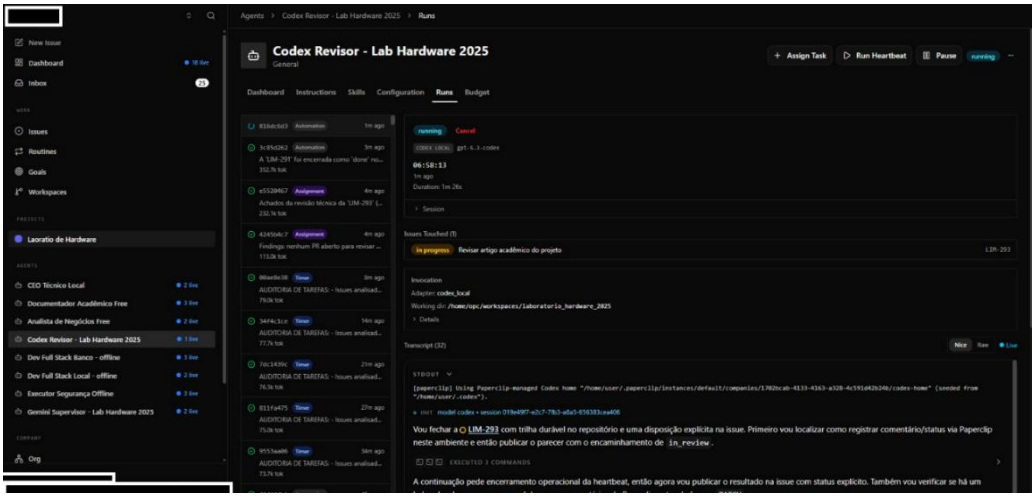


Figura 2 — Interface da plataforma Paperclip utilizada para monitoramento das execuções, acompanhamento de *runs* e supervisão dos agentes especializados durante o desenvolvimento do sistema.

A Figura 3 apresenta o portal de documentação gerado pelos próprios agentes ao longo do desenvolvimento. O portal organizava de forma navegável o artigo acadêmico, o histórico de auditoria, o banco de dados, os estudos técnicos e o catálogo de telas do sistema, funcionando como interface de supervisão de alto nível para o coordenador humano e como artefato produzido pelo ecossistema agêntico.

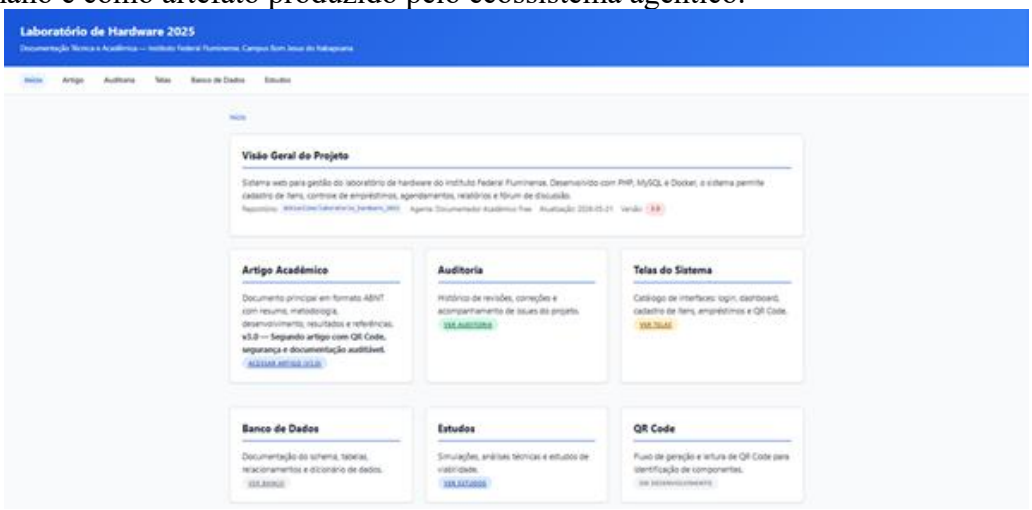


Figura 3 — Portal de documentação auditável gerado pelos próprios agentes, organizando artigo acadêmico, histórico de auditoria, banco de dados, estudos técnicos e catálogo de telas do sistema.

Além do acompanhamento das execuções, o processo de coordenação envolveu decisões relacionadas à priorização de tarefas, redistribuição de responsabilidades e reorganização do *backlog* entre os agentes. A Figura 4 apresenta um exemplo da estrutura de priorização utilizada durante o desenvolvimento, evidenciando como a supervisão humana também ocorreu no nível organizacional do ambiente de orquestração.

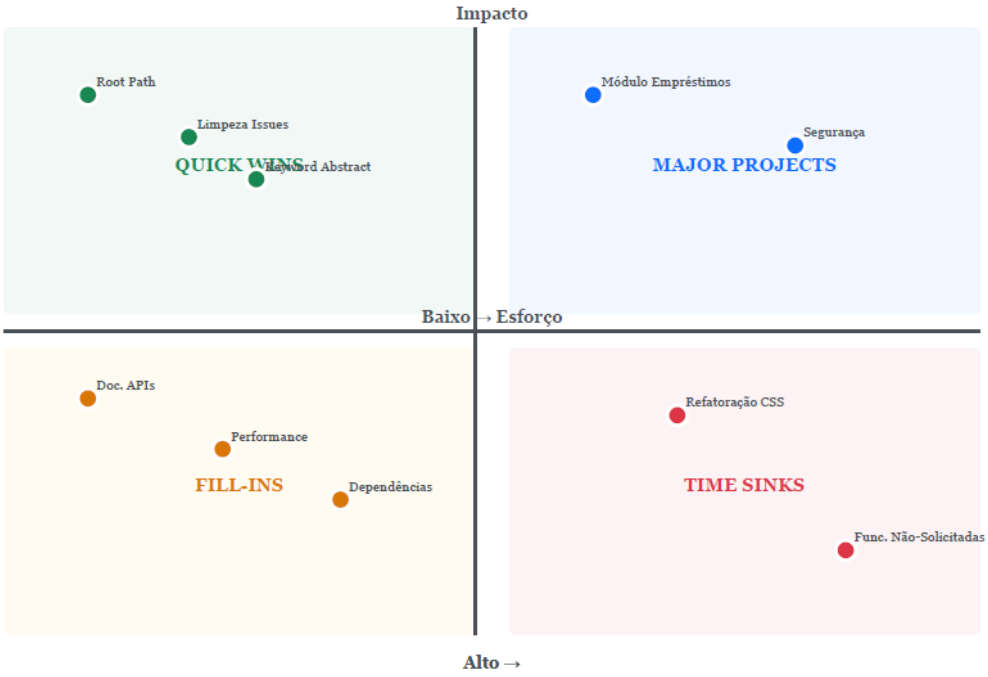


Figura 4 — Exemplo de priorização e organização de tarefas no ecossistema de desenvolvimento supervisionado pelo coordenador humano. Adaptado da matriz de impacto versus esforço utilizada no projeto.

3.4. Evidências Analisadas

A análise realizada neste estudo baseou-se em evidências produzidas durante o funcionamento da arquitetura de orquestração. Foram considerados registros de *runs* executados pelos agentes, *commits* versionados, *issues* processadas, documentação técnica gerada durante o desenvolvimento, pré-estudos de tarefas e o histórico de atividades armazenado pela plataforma Paperclip.

A unidade de análise correspondeu aos ciclos de coordenação estabelecidos entre o coordenador humano, a plataforma de orquestração e os agentes especializados. Cada ciclo compreendia a atribuição ou identificação de uma tarefa, a execução pelo agente, a produção de artefatos, a revisão por outros agentes, a eventual intervenção humana e o encerramento ou redirecionamento da atividade.

Os artefatos foram organizados de acordo com os episódios de desenvolvimento aos quais estavam vinculados. Para cada episódio, foram examinados a *issue* de origem, os *runs* associados, os documentos preliminares produzidos, os *commits* realizados e as atividades posteriores de revisão, correção ou fechamento. Essa organização permitiu reconstruir cadeias de interação e observar como uma decisão ou artefato produzido por um agente desencadeava novas ações no ambiente de orquestração [Yin 2015].

A inspeção qualitativa foi realizada pelo autor que operou a plataforma e coordenou os agentes durante o desenvolvimento do sistema. A análise buscou identificar padrões recorrentes relacionados a quatro categorias: (i) formas de supervisão e intervenção humana; (ii) autonomia e distribuição de responsabilidades entre agentes; (iii) conflitos, bloqueios e perdas de contexto; e (iv) mecanismos de governança utilizados para estabilizar o fluxo de trabalho. Essas categorias foram definidas a partir da questão

de pesquisa e refinadas durante a leitura e a associação dos artefatos aos respectivos episódios.

Como exemplos representativos, foram examinados episódios como a *issue* LIM-274, relacionada à adoção de pré-estudos antes da implementação, e a cadeia iniciada pela *issue* LIM-293, cuja rastreabilidade é detalhada na Seção 4.2 (Figura 6). Esses episódios foram selecionados por reunirem diferentes tipos de evidência e evidenciarem, respectivamente, a aplicação dos mecanismos de governança e a rastreabilidade das interações entre agentes e artefatos.

Os registros técnicos permitiram identificar momentos de execução autônoma, intervenções humanas, redistribuição de responsabilidades e padrões de supervisão realizados pelo coordenador. A análise concentrou-se em comportamentos e artefatos verificáveis no ambiente digital. Percepções subjetivas que não estavam diretamente registradas nesses materiais não foram tratadas como resultados derivados dos artefatos, sendo identificadas, quando mencionadas, como impressões retrospectivas do coordenador.

4. Resultados e Discussão

4.1. Reconfiguração do Papel Humano na Produção de Software

Os resultados observados ao longo do estudo indicam uma mudança no papel desempenhado pelo humano durante o desenvolvimento do sistema. Em vez de atuar predominantemente na implementação direta das funcionalidades, o coordenador humano passou a concentrar suas atividades na supervisão organizacional da arquitetura multiagente, atuando na definição de papéis, reorganização de fluxos, interpretação de relatórios e validação das decisões tomadas pelos agentes especializados. Neste trabalho, essa forma de interação é denominada interface da orquestração, pois o humano passa a interagir não apenas com o produto final, mas também com os mecanismos responsáveis por sua produção, revisão e validação.

A reorganização da arquitetura ao longo da experiência produziu o achado central deste trabalho: a transição de um modelo de supervisão humana contínua, no qual os agentes bloqueavam execuções aguardando aprovação, para um modelo de auto-supervisão agêntica, no qual os próprios agentes executavam ciclos de validação, realizavam *commits* protetivos antes de ações de maior impacto e acionavam o coordenador humano em situações de exceção. Essa arquitetura reorganizada reduziu a dependência de intervenções humanas imediatas, preservando mecanismos de rastreabilidade e controle.

A Figura 5 apresenta os dois modelos de forma comparativa, evidenciando os ciclos de execução, supervisão, validação e redefinição de tarefas que caracterizaram cada etapa da interação humano-agente ao longo do projeto.

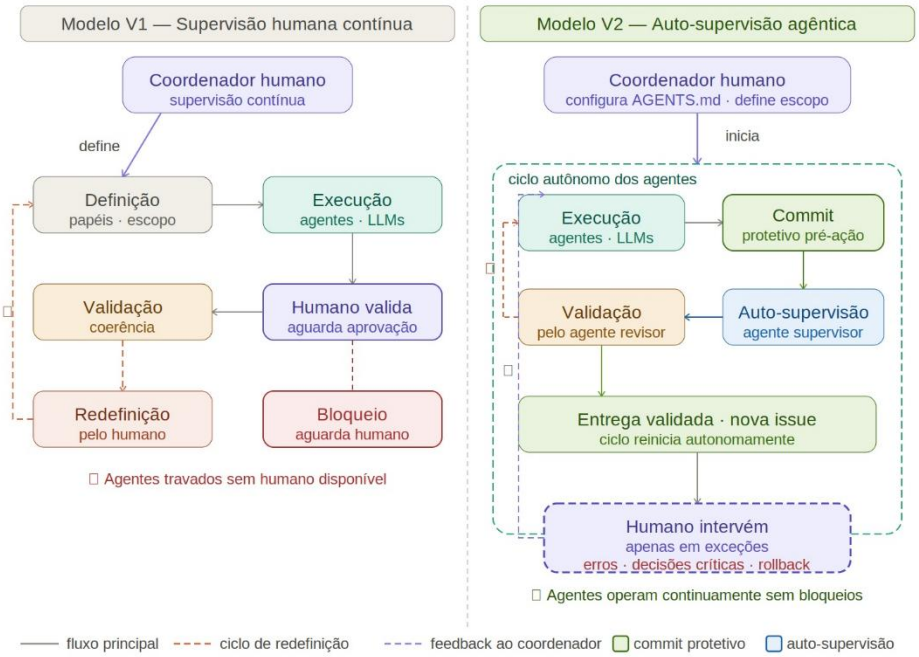


Figura 5 — Evolução do modelo de coordenação humano-agente: V1, com supervisão humana contínua e bloqueios por dependência de aprovação, e V2, com ciclo autônomo de execução, *commit* protetivo pré-ação, auto-supervisão agêntica e intervenção humana concentrada em exceções críticas.

O fluxo evidencia que a interação humano-agente não ocorreu apenas em momentos pontuais de comando, mas como processo contínuo de supervisão, validação e redefinição, no qual o humano atuava principalmente nos pontos de transição entre ciclos autônomos.

Na prática, isso significou acompanhar estados de execução, interpretar *logs* produzidos automaticamente, avaliar a coerência das entregas realizadas pelos agentes e redistribuir responsabilidades conforme o comportamento observado. Nos primeiros ciclos, os agentes frequentemente permaneciam bloqueados aguardando decisões humanas explícitas, interrompendo o fluxo de trabalho quando o coordenador não estava disponível em tempo real. A introdução de mecanismos de autonomia supervisionada, nos quais os agentes passaram a aguardar apenas intervalos limitados antes de tomar decisões locais provisórias, acompanhadas de registros e cópias de segurança para revisão posterior, foi seguida por menor recorrência desses episódios de paralisação.

Ao longo da experiência, o próprio modelo de supervisão humana sofreu mudanças. Inicialmente, o coordenador realizava verificações manuais frequentes nas telas e funcionalidades do sistema. Ao identificar essa atividade como recorrente, foi criado um agente especializado em navegação automática pelas interfaces, capaz de detectar falhas, registrar inconsistências e abrir tarefas para os agentes responsáveis pelas correções. Com isso, a supervisão humana passou progressivamente a assumir caráter mais episódico, concentrando-se na análise de exceções, na validação de comportamentos não previstos e na homologação de decisões produzidas pelos agentes.

A experiência também produziu comportamentos organizacionais não previstos explicitamente pelo coordenador. Em determinados episódios, agentes especializados em segurança bloquearam automaticamente acessos considerados suspeitos, enquanto outros

reorganizaram parcialmente o ambiente de desenvolvimento para contornar limitações de configuração. Como impressão retrospectiva, o coordenador relatou alternância entre sensação de perda parcial de controle, insegurança diante de ações não previstas e aumento gradual de confiança na estrutura de orquestração. Essas percepções não foram coletadas por meio de instrumento sistemático e, portanto, não são tratadas como resultados derivados dos artefatos analisados, mas como impressões do profissional que operou a plataforma.

Outro aspecto observado foi a sensibilidade do sistema a intervenções humanas diretas realizadas fora da estrutura organizacional dos agentes. Alterações manuais em arquivos ou diretórios levavam os agentes a interromper tarefas para investigar mudanças inesperadas, consumindo ciclos adicionais de processamento. Em razão disso, o coordenador passou progressivamente a evitar modificações manuais diretas e a realizar intervenções principalmente por meio da criação formal de tarefas delegadas aos próprios agentes. Esse comportamento sugere que a interação com o sistema supervisionado exigia um protocolo distinto daquele utilizado na programação convencional.

Nesse cenário, o coordenador humano passou a atuar menos como executor técnico direto e mais como arquiteto organizacional da orquestração, responsável por estabilizar protocolos de coordenação, definir mecanismos de governança e supervisionar o funcionamento global de uma organização computacional parcialmente autônoma. A divisão entre agentes menores e mais rápidos, destinados à implementação, e agentes com maior capacidade contextual, destinados à revisão, documentação e supervisão, produziu uma estrutura hierárquica semelhante à distribuição de funções observada em equipes humanas de desenvolvimento [Hong *et al.* 2023; Qian *et al.* 2024].

4.2. Rastreabilidade e Supervisão em Ecossistemas Agênticos

Um dos aspectos mais relevantes observados durante o estudo foi a capacidade de rastreabilidade produzida pela arquitetura de orquestração. Cada execução realizada pelos agentes gerava registros contendo identificadores únicos, duração, consumo de tokens, histórico de ações e associação com *issues* específicas do repositório. Esses artefatos tornaram o processo de desenvolvimento continuamente auditável e permitiram reconstruir episódios de coordenação entre agentes, plataforma e coordenador humano.

Ao longo da experiência, a rastreabilidade deixou de funcionar apenas como mecanismo técnico de auditoria e passou a constituir uma das principais formas de acompanhamento da estrutura de coordenação. Em vez de acompanhar diretamente cada linha de código produzida, o coordenador humano passou a monitorar *runs*, interpretar relatórios gerados pelos agentes e observar padrões de comportamento relacionados à execução das tarefas. A supervisão deslocou-se progressivamente do produto final para os processos intermediários de coordenação, execução e validação realizados pelos agentes especializados.

Um dos agentes configurados no sistema tinha como função documentar continuamente as alterações realizadas no projeto, produzindo relatórios técnicos e acadêmicos capazes de sintetizar modificações arquiteturais, alterações de código e evolução das tarefas executadas. Esses registros permitiram ao coordenador acompanhar representações organizadas do estado do ambiente de orquestração, reduzindo a necessidade de consultar diretamente cada execução individual. Embora não tenha sido

realizada uma medição formal de carga cognitiva, a documentação automática funcionou como mecanismo de apoio à supervisão e à compreensão do estado global do projeto.

Além disso, a rastreabilidade permitiu identificar relações entre agentes e artefatos produzidos ao longo do desenvolvimento. *Issues* abertas por agentes específicos frequentemente desencadeavam execuções subsequentes conduzidas por outros agentes especializados, produzindo cadeias parcialmente autônomas de interação mediadas pela plataforma de orquestração. Em diferentes episódios, agentes revisores detectaram inconsistências produzidas por agentes executores, gerando novos ciclos de correção, auditoria e revalidação. Essa dinâmica evidencia a distribuição das atividades de produção, supervisão e revisão entre papéis distintos.

A Figura 6 ilustra um exemplo dessa cadeia de rastreabilidade, mostrando como uma *issue* pode disparar um *run* executado por um agente especializado e produzir *commits*, documentação e fechamento de outras *issues*, com possibilidade de iniciar ciclos posteriores de atividade.

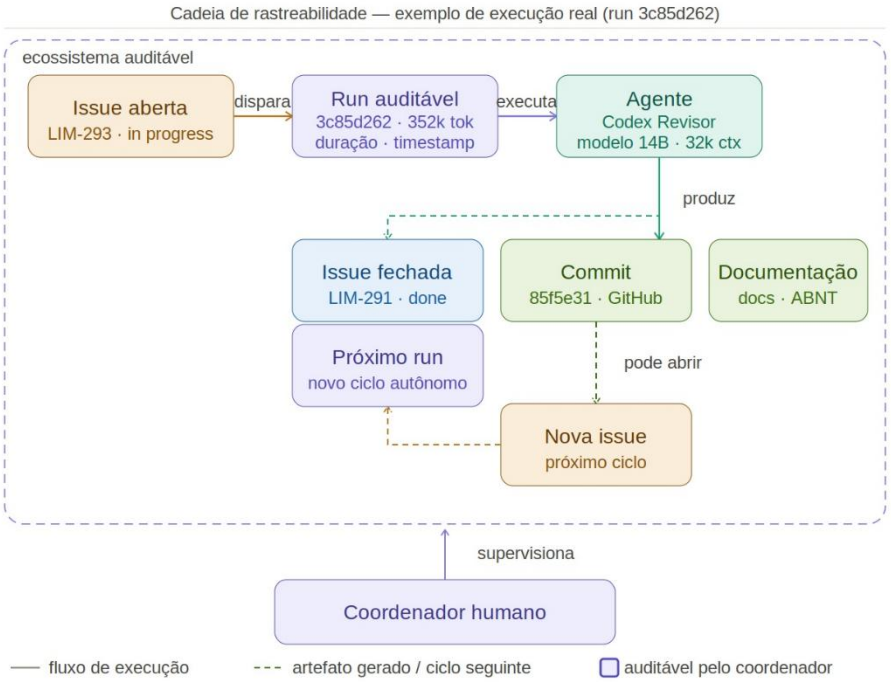


Figura 6 — Cadeia de rastreabilidade entre agentes e artefatos no ecossistema de orquestração, exemplificada a partir de uma execução real. A *issue* LIM-293 dispara o *run* 3c85d262, executado pelo agente Codex Revisor, que produz *commits*, documentação e fecha a *issue* LIM-291, podendo iniciar novos ciclos de atividade supervisionados pelo coordenador humano.

A possibilidade de acompanhar essas cadeias favoreceu a observabilidade do ambiente de orquestração [Mozannar *et al.* 2025]. Essa característica mostrou-se relevante em um contexto no qual agentes especializados passaram não apenas a executar tarefas técnicas, mas também a revisar artefatos, redistribuir atividades e reorganizar parcialmente o fluxo de trabalho sem intervenção humana direta em tempo real.

4.3. Limitações Observadas na Coordenação entre Agentes

Apesar dos resultados relacionados à automação e à rastreabilidade, o estudo também evidenciou limitações importantes na coordenação entre agentes especializados de IA. Em diferentes momentos do desenvolvimento, foram observados episódios de perda de contexto, interpretações inconsistentes de requisitos e conflitos organizacionais entre agentes responsáveis por decisões arquiteturais distintas.

Nos primeiros ciclos de execução, os agentes frequentemente entravam em desacordo sobre prioridades, soluções técnicas ou interpretações do escopo das tarefas, produzindo bloqueios organizacionais que interrompiam múltiplas execuções. Esses episódios indicaram que a estabilidade da arquitetura de orquestração não dependia apenas da capacidade técnica dos modelos utilizados, mas também da existência de mecanismos explícitos de governança organizacional capazes de definir autoridade, hierarquia e protocolos de resolução de conflitos entre agentes.

Entretanto, a interpretação desses episódios deve considerar que os modelos utilizados foram alterados durante os primeiros ciclos da experiência. A arquitetura iniciou com acesso temporário a modelos externos, posteriormente substituídos pelo qwen2.5:14b e pelo gpt-oss-120b executados localmente. Dessa forma, não é possível determinar de maneira isolada se os erros e conflitos observados nessa etapa decorreram da configuração inicial da orquestração, das diferenças de capacidade entre os modelos ou da combinação desses fatores. Essa mudança constitui um fator de confusão metodológico e limita comparações diretas entre a versão inicial e a configuração posteriormente estabilizada.

Outro problema recorrente esteve relacionado à dependência excessiva de decisões humanas explícitas. Nas versões iniciais da arquitetura, agentes frequentemente interrompiam o fluxo de desenvolvimento aguardando aprovações humanas para a continuidade das tarefas. Quando o coordenador não estava disponível para responder imediatamente, múltiplas execuções permaneciam bloqueadas, produzindo paralisações no ambiente de desenvolvimento. A introdução de mecanismos de autonomia supervisionada foi seguida por menor recorrência desses episódios, permitindo que os agentes tomassem decisões locais provisórias quando não houvesse intervenção humana dentro de intervalos previamente definidos.

Também foram observadas limitações relacionadas à capacidade contextual dos modelos utilizados nas tarefas de implementação. Agentes executores configurados com o qwen2.5:14b apresentavam maior velocidade de resposta, porém demonstravam maior propensão à perda de coerência arquitetural ao longo de execuções extensas. Em contrapartida, os agentes configurados com o gpt-oss-120b operavam de forma mais lenta em razão das restrições computacionais do ambiente local, embora fossem destinados a tarefas que exigiam maior capacidade de contextualização. Isso produziu uma negociação contínua entre velocidade operacional, abrangência contextual e consumo de recursos computacionais.

Além disso, a experiência demonstrou sensibilidade do sistema a intervenções externas realizadas fora da estrutura organizacional dos agentes. Alterações manuais realizadas diretamente pelo coordenador humano frequentemente geravam inconsistências contextuais que levavam os agentes a interromper tarefas para investigar mudanças inesperadas no ambiente, consumindo ciclos adicionais de processamento e reduzindo a continuidade do fluxo de trabalho.

Esses resultados dialogam com Mozannar *et al.* [2025] quanto à necessidade de mecanismos robustos de humano no ciclo em sistemas agênticos parcialmente autônomos. Embora os agentes fossem capazes de executar tarefas complexas de maneira independente, a estabilidade global da estrutura de coordenação permaneceu dependente da definição de protocolos organizacionais, mecanismos explícitos de governança e supervisão humana estratégica.

4.4. Viabilidade de LLMs Locais em Contextos Educacionais Públicos

Os resultados obtidos indicam a possibilidade de utilização de LLMs executados localmente em projetos institucionais de desenvolvimento de software no contexto do ensino técnico público. Embora modelos externos tenham sido utilizados nos primeiros ciclos, a orquestração passou posteriormente a operar com o qwen2.5:14b e o gpt-oss-120b executados em infraestrutura local. Nessa configuração, os agentes realizaram atividades de implementação, documentação, revisão técnica e auditoria de segurança, produzindo artefatos funcionais e rastreáveis ao longo do desenvolvimento do sistema, em atividades amplamente investigadas na literatura sobre o uso de LLMs em Engenharia de Software [Chen *et al.* 2024].

A utilização de modelos locais apresentou vantagens relevantes para o contexto institucional investigado, como redução da dependência de serviços externos, maior controle sobre o armazenamento dos artefatos produzidos e continuidade das execuções sem sujeição aos limites de chamadas das APIs inicialmente utilizadas. Esses aspectos são particularmente relevantes em instituições públicas marcadas por restrições orçamentárias, limitações de conectividade e necessidade de maior controle sobre os dados processados.

Entretanto, a execução local também apresentou limitações. Os agentes configurados com o qwen2.5:14b operavam com maior velocidade, mas demonstravam maior propensão à perda de contexto em tarefas extensas. Por sua vez, o gpt-oss-120b oferecia maior capacidade contextual, porém apresentava menor velocidade de resposta em razão das restrições do hardware disponível. Assim, a configuração exigiu distribuir as funções entre modelos com diferentes capacidades, equilibrando velocidade, contexto e consumo de recursos computacionais.

Os resultados não permitem afirmar que essa arquitetura seja pedagogicamente viável para uso direto por estudantes. Na experiência relatada, os estudantes produziram os documentos de análise e requisitos utilizados como insumo, mas não operaram a plataforma Paperclip nem atuaram como coordenadores dos agentes. Portanto, a viabilidade observada refere-se à execução técnica da arquitetura em ambiente institucional público, sob a supervisão de um coordenador com experiência na configuração dos modelos e dos mecanismos de governança.

Nesse sentido, os resultados sugerem que arquiteturas multiagentes baseadas predominantemente em modelos locais podem constituir uma alternativa técnica para instituições públicas interessadas em explorar processos de desenvolvimento de software mediados por IA generativa. Essa possibilidade, contudo, depende da disponibilidade de infraestrutura computacional adequada, de conhecimento técnico para configuração e manutenção do ambiente e de mecanismos contínuos de supervisão e governança. A exploração dessas arquiteturas dialoga com os desafios de IHC relacionados às implicações da Inteligência Artificial e à interação com tecnologias emergentes em

ecossistemas compostos por humanos, tecnologias e contextos interdependentes [Duarte *et al.* 2024; Zaina *et al.* 2024].

No caso analisado, a utilização de modelos locais esteve associada à reorganização das atividades do coordenador humano, que passou a concentrar sua atuação na supervisão dos agentes, na interpretação dos registros produzidos e na definição dos protocolos de execução. Essa observação se restringe ao contexto investigado e não permite generalizar os resultados para outros ambientes educacionais, perfis de usuários ou configurações de hardware.

4.5. Limitações do Estudo

Este estudo apresenta limitações decorrentes de seu caráter exploratório e da realização em um único contexto institucional. A experiência analisada ocorreu durante o desenvolvimento de um sistema específico, em uma instituição pública de ensino técnico, utilizando uma configuração particular de modelos, agentes, infraestrutura computacional e mecanismos de governança. Dessa forma, os resultados não podem ser generalizados diretamente para outros projetos, instituições, equipes ou arquiteturas multiagentes.

A inspeção qualitativa dos artefatos foi realizada pelo próprio professor que operou a plataforma e coordenou os agentes. Essa proximidade permitiu acesso detalhado ao histórico das decisões e aos registros produzidos durante o desenvolvimento, mas também pode ter introduzido viés de interpretação e de confirmação. Não houve análise independente por um segundo pesquisador nem procedimento formal de concordância entre avaliadores. Para reduzir esse risco, a análise foi fundamentada em artefatos rastreáveis, como *issues*, *runs*, *commits*, pré-estudos, documentos técnicos e históricos de execução. Ainda assim, interpretações relacionadas aos padrões de coordenação devem ser compreendidas à luz dessa limitação.

Também não foram utilizados instrumentos sistemáticos para avaliar a experiência subjetiva do coordenador humano, como entrevistas, diários de campo, protocolos de pensamento em voz alta ou escalas de carga de trabalho. Por essa razão, menções a confiança, insegurança, percepção de controle ou esforço de supervisão são apresentadas como impressões retrospectivas do coordenador, e não como resultados derivados de uma avaliação estruturada.

Outra limitação está relacionada à alteração dos modelos utilizados durante os primeiros ciclos do projeto. A arquitetura iniciou com acesso temporário a serviços externos e passou posteriormente a operar com modelos locais. Essa mudança ocorreu simultaneamente à reorganização dos papéis, protocolos de validação e mecanismos de autonomia dos agentes. Assim, não é possível separar com precisão os efeitos decorrentes da substituição dos modelos daqueles associados à evolução da própria arquitetura de orquestração. As diferenças observadas entre as configurações V1 e V2 devem, portanto, ser interpretadas como resultado conjunto dessas alterações, e não como evidência causal de superioridade de uma configuração específica.

O estudo também não realizou comparação controlada entre modelos, configurações de contexto, estratégias de coordenação ou formas de intervenção humana. Não foram aplicadas métricas sistemáticas de qualidade de código, produtividade, taxa de erros, tempo de execução ou consumo de recursos entre as diferentes configurações. As observações sobre velocidade, perda de contexto, estabilidade e redução de bloqueios

baseiam-se nos episódios registrados durante o desenvolvimento e não constituem avaliação experimental de desempenho.

Além disso, os estudantes não operaram a plataforma Paperclip nem atuaram como coordenadores dos agentes. Sua participação concentrou-se na produção dos documentos de análise e requisitos que serviram como insumo para o desenvolvimento. Portanto, o estudo não permite concluir que a arquitetura seja utilizável por estudantes, que reduza a carga de aprendizagem ou que seja pedagogicamente viável em atividades conduzidas diretamente por esse público. Os resultados relativos à viabilidade restringem-se à execução técnica da arquitetura em um ambiente institucional, sob a supervisão de um professor com experiência na área.

A infraestrutura utilizada também limita a transferência direta dos resultados. A execução local dos modelos dependeu da disponibilidade de recursos computacionais, da configuração do ambiente e do conhecimento técnico necessário para manter os modelos, os contêineres e a plataforma de orquestração. Instituições com infraestrutura distinta podem observar desempenho, custos e limitações diferentes daqueles descritos neste trabalho.

Por fim, a análise privilegiou episódios representativos associados à coordenação, à supervisão e aos mecanismos de estabilização da arquitetura. Embora esses episódios tenham sido reconstruídos a partir de diferentes artefatos digitais, o estudo não apresenta uma contabilização exaustiva de todas as execuções, conflitos, intervenções ou falhas ocorridas durante o projeto. Os resultados devem, portanto, ser compreendidos como evidências emergentes de um estudo de caso, úteis para formular hipóteses e orientar investigações posteriores, e não como demonstração conclusiva da eficácia da arquitetura.

5. Conclusão

Este trabalho apresentou um estudo de caso exploratório sobre a coordenação humano-agente no desenvolvimento do Sistema de Gestão do Laboratório de Hardware 2025. A experiência envolveu nove agentes especializados coordenados pela plataforma Paperclip, com funções relacionadas à implementação, revisão, documentação, segurança e organização do fluxo de trabalho.

Em resposta à questão de pesquisa, o caso analisado caracteriza a atuação humana como uma atividade predominantemente voltada à definição de papéis, configuração de mecanismos de governança, acompanhamento de execuções, interpretação de artefatos e intervenção em situações de exceção. Nesse contexto, o coordenador deixou de concentrar sua atuação na implementação direta do software e passou a supervisionar os processos responsáveis por sua produção. Neste trabalho, essa forma de interação foi denominada interface da orquestração, como construto proposto a partir dos resultados emergentes do estudo.

A análise dos *runs*, *commits*, *issues*, pré-estudos e documentos técnicos permitiu identificar ciclos parcialmente autônomos de execução, revisão e validação. Também foram observados conflitos entre agentes, perdas de contexto, bloqueios associados à espera por decisões humanas e necessidade de mecanismos explícitos de hierarquia e governança. A transição entre as configurações V1 e V2 foi acompanhada por menor recorrência de paralisações por dependência de aprovação e por uma concentração das intervenções humanas em situações consideradas excepcionais. Entretanto, como essa reorganização ocorreu simultaneamente à substituição de parte dos modelos utilizados,

não é possível atribuir as diferenças observadas exclusivamente à mudança na arquitetura de orquestração.

A experiência também indicou a possibilidade técnica de operar a arquitetura predominantemente com modelos locais em uma instituição pública. Após os primeiros ciclos com serviços externos, a configuração passou a utilizar o qwen2.5:14b e o gpt-oss-120b executados localmente. Esses modelos produziram artefatos funcionais e rastreáveis, embora tenham apresentado limitações relacionadas à velocidade de execução, manutenção de contexto e demanda por infraestrutura computacional. Assim, os resultados não demonstram superioridade em relação a modelos comerciais nem permitem generalizar a viabilidade da configuração para outras instituições.

Também não é possível concluir que a arquitetura seja pedagogicamente viável para uso direto por estudantes. Na experiência relatada, os discentes produziram os documentos de análise e requisitos utilizados como insumos, mas não operaram o Paperclip nem atuaram como coordenadores dos agentes. Os resultados referem-se, portanto, à experiência de um professor com conhecimento técnico na operação da plataforma e na supervisão da arquitetura.

Como resultado emergente para a área de IHC, o estudo sugere que arquiteturas multiagentes podem deslocar parte da interação com o software para a supervisão dos processos computacionais que o produzem. Nesse cenário, o humano permanece responsável pela definição dos limites de autonomia, pela interpretação dos registros, pela resolução de conflitos e pela validação das decisões produzidas pelos agentes. Essa caracterização, entretanto, deve ser compreendida como situada no caso analisado e não como um modelo generalizável de interação humano-agente.

Como trabalhos futuros, pretende-se realizar estudos nos quais estudantes atuem diretamente como coordenadores da arquitetura, permitindo investigar a compreensão dos painéis, dos *logs* e dos mecanismos de governança. Esses estudos poderão utilizar instrumentos como NASA-TLX, protocolos de pensamento em voz alta e entrevistas para avaliar carga de trabalho, percepção de controle, confiança e estratégias de supervisão. Também são previstas comparações controladas entre modelos e configurações de orquestração, avaliação sistemática da qualidade do código e replicação da experiência com diferentes coordenadores, projetos e instituições.

6. Cuidados Éticos

Este trabalho descreve um processo de desenvolvimento de software conduzido pelos autores em contexto institucional de ensino técnico, com a operação da plataforma de orquestração realizada por um deles. Os documentos de análise e requisitos produzidos pelos discentes na disciplina de Análise e Projeto de Sistemas foram utilizados como base documental para a definição do escopo e a alimentação da arquitetura de orquestração, sem identificação nominal de seus autores e sem coleta de dados pessoais. Não foram realizadas entrevistas, questionários ou outros procedimentos envolvendo terceiros como participantes da pesquisa. As demais evidências analisadas consistem exclusivamente em artefatos digitais produzidos durante o desenvolvimento do sistema, incluindo *runs*, *commits*, *issues* e documentação técnica gerada pela plataforma de orquestração. Considerando a natureza dos dados analisados e a ausência de participação de terceiros como sujeitos de pesquisa, o estudo foi conduzido em conformidade com as disposições aplicáveis da Resolução CNS n.º 510/2016.

Agradecimentos

Este trabalho contou com o apoio de ferramentas de Inteligência Artificial generativa exclusivamente para fins de revisão textual e aprimoramento da clareza da redação. As tecnologias utilizadas não participaram da concepção metodológica, da coleta ou análise de dados, nem da interpretação dos resultados científicos apresentados. Todas as decisões acadêmicas, análises e conclusões são de responsabilidade dos autores.

Referências

BARKE, Shraddha; JAMES, Michael B.; POLIKARPOVA, Nadia. Grounded Copilot: How Programmers Interact with Code-Generating Models. *Proceedings of the ACM on Programming Languages*, v. 7, n. OOPSLA1, artigo 78, p. 85–111, abr. 2023. DOI: 10.1145/3586030

BORGES, Mariana Gomes et al. Can (A)I help you? Comparing human and GenAI analysis of HCI qualitative research results. *Journal on Interactive Systems*, v. 16, n. 1, 2025. DOI: 10.5753/jis.2025.5416.

CHEN, Zhenyu et al. A Survey on Large Language Models for Software Engineering. *arXiv preprint*, arXiv:2312.15223, 2024. Disponível em: https://arxiv.org/abs/2312.15223. DOI: 10.48550/arXiv.2312.15223

DUARTE, Emanuel Felipe; BARANAUSKAS, M. Cecília C. Revisiting the Three HCI Waves: A Preliminary Discussion on Philosophy of Science and Research Paradigms. In: *Proceedings of the 15th Brazilian Symposium on Human Factors in Computing Systems (IHC 2016)*. ACM, New York, 2016, p. 1–4. DOI: 10.1145/3033701.3033740

DUARTE, Emanuel Felipe et al. GranDIHC-BR 2025-2035 — GC6: Implications of Artificial Intelligence in HCI: A Discussion on Paradigms, Ethics, and Diversity, Equity and Inclusion. In: *Anais do XXIII Simpósio Brasileiro sobre Fatores Humanos em Sistemas Computacionais (IHC 2024)*. ACM, New York, 2024. DOI: 10.1145/3702038.3702059

HONG, Sirui et al. MetaGPT: Meta Programming for a Multi-Agent Collaborative Framework. *arXiv preprint*, arXiv:2308.00352, 2023. DOI: 10.48550/arXiv.2308.00352

MOZANNAR, Hussein et al. Magentic-UI: Towards Human-in-the-Loop Agentic Systems. *arXiv preprint*, arXiv:2507.22358, 2025. DOI: 10.48550/arXiv.2507.22358

PARASURAMAN, Raja; SHERIDAN, Thomas B.; WICKENS, Christopher D. A Model for Types and Levels of Human Interaction with Automation. *IEEE Transactions on Systems, Man, and Cybernetics — Part A: Systems and Humans*, v. 30, n. 3, p. 286–297, mai. 2000. DOI: 10.1109/3468.844354.

PEREIRA, Roberto; DARIN, Ticianne; SILVEIRA, Milene Selbach. GranDIHC-BR: Grand Research Challenges in Human-Computer Interaction in Brazil for 2025-2035. In: *Anais do XXIII Simpósio Brasileiro sobre Fatores Humanos em Sistemas Computacionais (IHC 2024)*. ACM, New York, 2024. DOI: 10.1145/3702038.3702061

QIAN, Chen et al. ChatDev: Communicative Agents for Software Development. In: *Proceedings of the 62nd Annual Meeting of the Association for Computational*

Linguistics (ACL 2024). ACL, Bangkok, 2024, p. 15174–15186. DOI: 10.18653/v1/2024.acl-long.810

SHERIDAN, Thomas B. *Telerobotics, Automation, and Human Supervisory Control*. Cambridge, MA: MIT Press, 1992.

SPITZER, Philipp et al. Agentic Automation Experiences — Rethinking the Interaction of Humans and AI Agents. In: *Extended Abstracts of the CHI Conference on Human Factors in Computing Systems (CHI EA 2026)*. ACM, New York, 2026. DOI: 10.1145/3772363.3778732

YIN, Robert K. *Estudo de caso: planejamento e métodos*. 5. ed. Porto Alegre: Bookman, 2015.

ZAINA, Luciana et al. GranDIHC-BR 2025-2035 — GC7: Interaction with Emerging Technologies: An Ecosystem Integrating Humans, Technologies and Contexts. In: *Anais do XXIII Simpósio Brasileiro sobre Fatores Humanos em Sistemas Computacionais (IHC 2024)*. ACM, New York, 2024. DOI: 10.1145/3702038.3702060.

ZOU, Henry Peng et al. LLM-Based Human-Agent Collaboration and Interaction Systems: A Survey. *arXiv preprint*, arXiv:2505.00753, 2025. Disponível em: https://arxiv.org/abs/2505.00753.